

МОСКОВСКИЙ ГОСУДАРСТВЕННЫЙ
УНИВЕРСИТЕТ
имени М. В. Ломоносова
ЭКОНОМИЧЕСКИЙ ФАКУЛЬТЕТ
КАФЕДРА МАТЕМАТИЧЕСКИХ МЕТОДОВ
АНАЛИЗА
ЭКОНОМИКИ

КУРСОВАЯ РАБОТА

«Применение машинного обучения
в задаче оптимизации инвестиционного портфеля»

Выполнил студент
группы Э-304:
Герцен Роман Андреевич

Научный руководитель:
доцент, кандидат
физико-математических наук
Артамонов Дмитрий
Вячеславович

Москва 2026

Содержание

1	Введение	3
2	Обзор литературы	5
2.1	Машинное обучение в финансах	5
2.2	Методология López de Prado	5
2.2.1	CUSUM-фильтр	6
2.2.2	Triple Barrier Method и meta-labeling	6
2.2.3	Взвешивание наблюдений	9
2.2.4	Fractional Differentiation	11
2.2.5	PurgedKFold и embargo	13
2.2.6	Настройка гиперпараметров	14
2.3	Размер позиции	15
3	Данные и их подготовка	16
3.1	Финансовые активы	16
3.2	Макроэкономические и рыночные индикаторы	17
3.3	Momentum-признаки	18
3.4	Volatility-признаки	18
3.5	Признаки максимальной просадки	19
3.6	Итоговая подготовка данных	19
4	Методология исследования	20
4.1	Формирование событий и целевой переменной	20
4.2	Обучение моделей	20
4.3	Размер позиции	21
4.4	Walk-forward backtesting	22
5	Результаты исследования	22
5.1	Результаты моделей машинного обучения	22
5.2	Финансовые результаты базовой ML-стратегии	24
5.3	Влияние масштабирования уверенности	26
6	Ограничения исследования	28

7 Заключение	29
Список литературы	29

1. Введение

В последние годы методы машинного обучения активно применяются в задачах количественных финансов и управления инвестиционными портфелями. Рост вычислительных мощностей, доступность больших объёмов данных и развитие алгоритмов машинного обучения привели к существенному расширению области применения подходов, основанных на данных, в финансовой индустрии. Однако финансовые временные ряды обладают рядом особенностей, существенно отличающих их от данных, используемых в классических задачах машинного обучения.

Финансовые данные характеризуются низким отношением сигнал/шум, высокой изменчивостью рыночных режимов, зависимостью наблюдений и нестационарностью. Кроме того, при работе с финансовыми временными рядами возникает проблема переобучения. Модель может демонстрировать высокое качество на исторических данных, но полностью терять предсказательную силу на новых наблюдениях. Вследствие этого использование стандартных методов машинного обучения без специализированной адаптации часто приводит к получению неустойчивых и экономически бессмысленных результатов.

Одним из наиболее известных современных подходов к решению данной проблемы является методология Financial Machine Learning, предложенная Маркосом Лопесом де Прадо в книге «Advances in Financial Machine Learning». В методологии особое внимание уделяется корректной разметке финансовых событий, устранению информационных утечек, построению зависимых выборок и использованию специализированных методов валидации. Одним из центральных элементов подхода является meta-labeling. Этот подход представляет собой дополнительный уровень классификации, позволяющий фильтровать торговые сигналы базовой стратегии.

В работе исследуется возможность применения meta-labeling для повышения эффективности инвестиционных стратегий на рынке ETF. В качестве базового сигнала используется momentum-подход, идея которого заключается в том, чтобы использовать в качестве сигнала доходность за последние n периодов. Задача моделей машинного обучения заключается в определении того, какие сигналы целесообразно принимать, а какие следует игнорировать.

Целью работы является исследование способности методов машинного обучения улучшать качество инвестиционных сигналов и снижать риск стратегии по сравнению с простыми momentum-подходами.

Для достижения поставленной цели решаются следующие задачи:

- сформировать набор финансовых и макроэкономических признаков для нескольких классов активов
- реализовать событийно-ориентированную выборку на основе CUSUM-фильтра
- построить разметку данных методом Triple Barrier Method
- применить Fractional Differentiation для стационаризации признаков
- реализовать meta-labeling pipeline
- обучить модели Logistic Regression, RandomForest и LightGBM
- реализовать корректное взвешивание наблюдений
- применить очищенную кросс-валидацию PurgedKFold с embargo
- провести walk-forward backtesting
- сравнить финансовые результаты ML-стратегий с базовыми momentum-стратегиями

Объектом исследования являются ETF, отражающие различные классы активов. В работе рассматриваются акции США, облигации, золото, недвижимость, товарные рынки, развивающиеся страны и индекс доллара.

Предметом исследования являются методы Financial Machine Learning для фильтрации инвестиционных сигналов и управления размером позиции.

Практическая значимость работы заключается в построении полного пайплайна финансового машинного обучения. Полученные результаты позволяют оценить применимость современных методов Financial Machine Learning к задачам управления инвестиционным портфелем.

2. Обзор литературы

2.1. Машинное обучение в финансах

Применение методов машинного обучения в финансах связано с рядом специфических трудностей. Финансовые временные ряды обладают выраженной нестационарностью, высокой долей шума и зависимостью наблюдений во времени. Также распределение доходностей может изменяться при смене рыночных режимов, что усложняет задачу построения устойчивых моделей.

Пусть доходность актива определяется как

$$r_t = \ln P_t - \ln P_{t-1}, \quad (2.1)$$

где P_t — цена актива в момент времени t .

В классических задачах машинного обучения обычно предполагается, что наблюдения независимы и одинаково распределены. Для финансовых данных это предположение неверно, так как наблюдения могут пересекаться по времени и использовать одну и ту же рыночную информацию. В результате стандартные методы кросс-валидации могут приводить к информационной утечке и переоценке качества моделей.

Дополнительная проблема связана с переобучением. При большом количестве признаков и сравнительно небольшом числе независимых событий модель может находить случайные закономерности, отсутствующие вне обучающей выборки. Поэтому для финансовых задач особенно важны корректная разметка событий, специальные методы валидации и честное out-of-sample тестирование.

2.2. Методология López de Prado

Основной теоретической базой работы является подход, предложенный Marcos López de Prado в книге «Advances in Financial Machine Learning».

В отличие от традиционного подхода, использующего равномерные временные интервалы, López de Prado предлагает формировать выборку только в моменты значимых рыночных изменений. Для этого применяется CUSUM-фильтр.

2.2.1. CUSUM-фильтр

CUSUM-фильтр позволяет выделять моменты существенных изменений цены. Для положительных и отрицательных накопленных изменений вычисляются величины

$$S_t^+ = \max(0, S_{t-1}^+ + r_t), \quad (2.2)$$

$$S_t^- = \min(0, S_{t-1}^- + r_t). \quad (2.3)$$

Событие фиксируется в случае выполнения условия

$$S_t^+ > h \quad \text{или} \quad |S_t^-| > h, \quad (2.4)$$

где h — порог фильтра.

В итоге выборку попадают только моменты, соответствующие значимым изменениям цен. Это снижает влияние шоков.

2.2.2. Triple Barrier Method и meta-labeling

Для разметки финансовых событий в работе используется Triple Barrier Method. Для каждого события задаются три барьера:

- верхний барьер прибыли
- нижний барьер убытка
- вертикальный временной барьер (означает, что доходность не вышла за границы).

Пусть событие возникает в момент времени t_0 . Для него задаётся вертикальный барьер t_1 , ограничивающий максимальную длительность сделки. В работе вертикальный барьер составлял 5 торговых дней.

В момент t_0 первичная модель формирует направление сделки:

$$side_{t_0} = \text{sign}(mom_{63,t_0}), \quad (2.5)$$

где mom_{63,t_0} — momentum за 63 торговых дня (то есть доходность за этот период).

Если *momentum* положителен, первичная модель предполагает длинную позицию (*side* = 1). Если *momentum* отрицателен, предполагается короткая позиция (*side* = -1).

После определения направления сделки строятся горизонтальные барьеры. Их расстояние зависит от текущей волатильности рынка:

$$pt = \theta_{pt} \sigma_{t_0}, \quad (2.6)$$

$$sl = -\theta_{sl} \sigma_{t_0}, \quad (2.7)$$

где σ_{t_0} — оценка волатильности в момент события.

В работе использовалась конфигурация:

$$ptSl = [1, 2]. \quad (2.8)$$

Это означает, что верхний барьер располагался на расстоянии одной волатильности, а нижний — на расстоянии двух волатильностей.

В отличие от обычной задачи прогнозирования направления цены, в meta-labeling доходность рассчитывается с учётом направления сделки:

$$r_t^{meta} = side_{t_0} \left(\frac{P_t}{P_{t_0}} - 1 \right). \quad (2.9)$$

Для длинной позиции рост цены соответствует положительной доходности, а для короткой позиции положительной доходности соответствует падение цены.

Дальше определяется первый момент времени, в который достигается один из трёх барьеров.

Пусть момент достижения первого барьера обозначается как t_1 . Тогда итоговая доходность события определяется как

$$r_i^{meta} = side_i \left(\frac{P_{t_1}}{P_{t_0}} - 1 \right). \quad (2.10)$$

После этого формируется бинарная meta-labeling метка:

$$y_i = \begin{cases} 1, & \text{если } r_i^{meta} > 0 \\ 0, & \text{если } r_i^{meta} \leq 0 \end{cases} \quad (2.11)$$

Модель машинного обучения прогнозирует не направление движения цены, а успешность первичного momentum-сигнала. Класс 1 соответствует прибыльной реализации сигнала первичной модели, а класс 0 — убыточной или нейтральной реализации.

Для иллюстрации рассмотрим пример. Пусть в момент времени t_0 цена ETF SPY составляет \$500, а цена 63 торговых дня назад равнялась \$480. Тогда momentum за 63 дня равен

$$mom_{63} = \frac{500}{480} - 1 = 0.0417. \quad (2.12)$$

Поскольку momentum положителен, первичная модель формирует длинную позицию:

$$side = +1. \quad (2.13)$$

Пусть оценка волатильности в момент события составляет $\sigma = 0.01$ (1%). При параметрах $ptSl = [1, 2]$ барьеры принимают вид:

$$PT = 500(1 + 1 \cdot 0.01) = 505, \quad (2.14)$$

$$SL = 500(1 - 2 \cdot 0.01) = 490. \quad (2.15)$$

Если через два дня цена достигает \$506, происходит касание верхнего барьера. Тогда реализованная доходность составляет

$$r^{meta} = 1 \cdot \left(\frac{506}{500} - 1 \right) = 0.012. \quad (2.16)$$

Поскольку доходность положительна, событию присваивается метка

$$y = 1. \quad (2.17)$$

Если же цена сначала снижается до \$488, происходит касание stop-loss барьера. Тогда

$$r^{meta} = 1 \cdot \left(\frac{488}{500} - 1 \right) = -0.024, \quad (2.18)$$

и событие получает метку (доходность с учетом side отрицательная)

$$y = 0. \quad (2.19)$$

Если за 5 торговых дней ни один из барьеров не был достигнут, сделка закрывается по вертикальному барьеру. Например, если итоговая цена составила \$501, то

$$r^{meta} = 1 \cdot \left(\frac{501}{500} - 1 \right) = 0.002. \quad (2.20)$$

Так как доходность остаётся положительной, событию также присваивается метка $y = 1$.

2.2.3. Взвешивание наблюдений

Финансовые события могут пересекаться во времени (происходит перекрытие). Если несколько сделок открыты одновременно, их результаты не являются независимыми, потому что они используют одну и ту же информацию.

Предположим, первое событие возникает 1 марта. Для него строится Triple Barrier разметка с вертикальным барьером 5 торговых дней. Это означает, что итог метки зависит от движения цены в период с 2 по 6 марта.

Затем 3 марта возникает новое событие. Для него также строится Triple Barrier разметка с вертикальным барьером 5 дней, поэтому его исход зависит от движения цены с 4 по 8 марта.

Получается, что оба события одновременно используют рыночные данные с 4 по 6 марта. Если в этот период рынок резко падает, то оба события с высокой вероятностью одновременно получают убыточный исход. Аналогично сильный рост рынка может одновременно привести к успешному завершению обеих сделок.

Следовательно, наблюдения оказываются положительно скоррелированными и не являются полностью независимыми. Если передать такие события модели как независимые наблюдения, то модель будет воспринимать одно и то же рыночное движение как несколько отдельных подтверждений закономерности. Это приводит к переоценке значимости признаков и увеличивает риск переобучения.

Для уменьшения проблемы в работе использовались uniqueness weights.

Их идея заключается в том, чтобы снижать вес событий, которые сильно пересекаются по времени с другими наблюдениями. Для учёта этой проблемы López de Prado вводит понятие uniqueness.

Пусть c_t — число одновременно активных событий в момент времени t . Для события i вводится индикатор активности $I_{t,i}$, который равен единице, если событие активно в момент t , и равен нулю в противном случае. Тогда уникальность события в момент времени t определяется как

$$u_{t,i} = \frac{I_{t,i}}{c_t}. \quad (2.21)$$

Средняя уникальность события равна

$$\bar{u}_i = \frac{1}{T_i} \sum_{t=t_{0,i}}^{t_{1,i}} \frac{I_{t,i}}{c_t}, \quad (2.22)$$

где T_i — длительность события.

Одной средней уникальности недостаточно. Даже если два события частично пересекаются, их вклад в обучение модели может различаться в зависимости от того, насколько сильным было движение рынка в период жизни события. Поэтому López de Prado дополнительно вводит механизм return attribution — приписывания доходности событиям.

Идея подхода состоит в том, что каждое событие должно получать только ту часть рыночного движения, которая действительно относится к нему. Если в некоторый момент времени одновременно активно несколько событий, то соответствующая доходность не должна полностью приписываться каждому из них, поскольку это привело бы к многократному учёту одного и того же движения цены.

Пусть в момент времени t одновременно активно c_t событий. Тогда логарифмическая доходность r_t делится между ними:

$$\frac{r_t}{c_t}. \quad (2.23)$$

Если в некоторый день активно только одно событие, оно получает всю доходность данного дня. Если одновременно открыты, например, четыре события, то каждое получает только четверть этой доходности.

После этого для каждого события суммируются все скорректированные

доходности за период его жизни:

$$\tilde{r}_i = \sum_{t=t_{0,i}}^{t_{1,i}} \frac{r_t}{c_t}. \quad (2.24)$$

Экономическая интуиция здесь состоит в следующем. Если большое число событий одновременно использует один и тот же рыночный тренд, то этот тренд не должен многократно усиливать влияние наблюдений на модель. Иначе модель будет воспринимать одно рыночное движение как множество независимых подтверждений закономерности. В результате возрастает риск переобучения.

Веса наблюдений строятся на основе приписанной доходности и уникальности события. После расчёта веса нормируются так, чтобы сумма весов соответствовала числу событий в выборке. Такой подход уменьшает влияние сильно пересекающихся наблюдений и повышает устойчивость моделей.

2.2.4. Fractional Differentiation

Многие финансовые ряды, особенно ценовые ряды, являются нестационарными. Для моделей машинного обучения это проблема, потому что модель может начать находить зависимость не между признаками и целевой переменной, а между общими трендами во времени. В таком случае качество на обучающей выборке может выглядеть высоким, но на новых данных модель будет работать нестабильно.

Самый простой способ сделать ценовой ряд стационарным — взять первую разность:

$$\Delta x_t = x_t - x_{t-1}. \quad (2.25)$$

Но у такого подхода есть недостаток: он сильно удаляет долгосрочную память ряда. Для финансовых данных это нежелательно, поскольку часть информации может содержаться именно в медленных изменениях уровня цены, трендах и длительных рыночных режимах. Поэтому возникает задача: сделать ряд более стационарным, но при этом не уничтожить всю память исходного процесса.

Для этого López de Prado предлагает использовать дробное дифферен-

цирование. В общем виде оно записывается как

$$(1 - L)^d x_t = \sum_{k=0}^{\infty} \omega_k x_{t-k}, \quad (2.26)$$

где L — оператор лага, d — дробный порядок дифференцирования, а веса ω_k рассчитываются рекурсивно:

$$\omega_k = -\omega_{k-1} \frac{d - k + 1}{k}. \quad (2.27)$$

Если $d = 0$, ряд остаётся почти без изменений. Если $d = 1$, получается обычная первая разность. Значения $0 < d < 1$ дают промежуточный вариант: ряд становится более стационарным, но сохраняет часть долгосрочной зависимости.

На практике бесконечная сумма не вычисляется. Идея приближенного метода состоит в том, что веса ω_k постепенно уменьшаются по модулю, поэтому после некоторого лага их вклад становится пренебрежимо малым. В работе веса рассчитывались до тех пор, пока выполнялось условие

$$|\omega_k| \geq \tau, \quad (2.28)$$

где τ — порог отсечения. После того как вес становился меньше порога, дальнейшие лаги не использовались. Бесконечная сумма заменялась конечным скользящим окном:

$$x_t^{FFD} = \sum_{k=0}^{l^*} \omega_k x_{t-k}, \quad (2.29)$$

где l^* — длина окна, определяемая порогом отсечения весов.

В работе сначала брались логарифмы цен ETF:

$$x_t = \ln P_t. \quad (2.30)$$

Затем для каждого ETF отдельно подбирался минимальный параметр d из диапазона от 0 до 1 с шагом 0.01. Для каждого значения d строился FFD-ряд, после чего проверялась его стационарность с помощью ADF-теста. В качестве критерия использовалось условие

$$p\text{-value} < 0.05. \quad (2.31)$$

Выбиралось минимальное значение d , при котором ряд становился стационарным. Если подходящее значение d не находилось, использовалось $d = 1$, что соответствует обычному дифференцированию.

2.2.5. PurgedKFold и embargo

Стандартная кросс-валидация плохо подходит для финансовых данных. В классических задачах машинного обучения обычно предполагается, что наблюдения независимы и одинаково распределены. Для финансовых временных рядов это предположение нарушается, поскольку метки событий строятся на основе будущего движения цены, а соседние события могут пересекаться по времени.

López de Prado предлагает использовать PurgedKFold — очищенную кросс-валидацию для финансовых данных.

Для каждого события задаются:

$$t_{0,i} \quad (2.32)$$

— момент начала события,

$$t_{1,i} \quad (2.33)$$

— момент завершения события после касания одного из барьеров.

При формировании тестового блока из обучающей выборки удаляются все наблюдения, временные интервалы которых пересекаются с тестовыми событиями.

Формально удаляются наблюдения, для которых выполняется хотя бы одно из условий:

$$t_{0,i} \leq t_{0,j} \leq t_{1,i}, \quad (2.34)$$

$$t_{0,i} \leq t_{1,j} \leq t_{1,i}, \quad (2.35)$$

$$t_{0,j} \leq t_{0,i} \leq t_{1,i} \leq t_{1,j}. \quad (2.36)$$

PurgedKFold предотвращает использование в обучении наблюдений, содержащих информацию о тестовом периоде.

Дополнительно в работе используется embargo. Даже после удаления пересекающихся событий может сохраняться проблема последовательной зависимости. Наблюдения, начинающиеся сразу после тестового блока, могут быть очень похожими на тестовые события из-за инерции рынка и автокорреляции признаков.

Для решения этой проблемы после тестового блока вводится дополнительный временной отрезок, который также исключается из обучения.

Пусть тестовый блок заканчивается в момент времени

$$t_{max}. \quad (2.37)$$

Тогда из обучающей выборки дополнительно удаляются наблюдения, начинающиеся на интервале

$$[t_{max}, t_{max} + hT], \quad (2.38)$$

где T — длина всей выборки, а h — доля embargo.

В работе использовались параметры:

- $n_splits = 3$
- $pctEmbargo = 0.02$

2.2.6. Настройка гиперпараметров

Подбор гиперпараметров моделей проводится с использованием очищенной кросс-валидации. Для моделей RandomForest и LightGBM применяется RandomizedSearchCV, а для Logistic Regression подбирается коэффициент регуляризации с помощью Grid search.

В качестве основной метрики используются macro-F1. Macro-F1 определяется как среднее значение F1-меры по классам:

$$F1_{macro} = \frac{1}{K} \sum_{k=1}^K F1_k. \quad (2.39)$$

2.3. Размер позиции

В работе вероятности, полученные на выходе моделей машинного обучения, использовались не только для бинарного решения о входе в сделку, но и для определения размера позиции.

После обучения meta-labeling модель для каждого события формировала вероятность успешности сигнала:

$$p_i = P(y_i = 1 \mid X_i), \quad (2.40)$$

где X_i — вектор признаков события i .

Вместо того чтобы принимать одинаковый размер позиции для всех сделок, вероятность использовалась для масштабирования позиции.

Сначала вероятность преобразовывалась в z-score:

$$z_i = \frac{p_i - 0.5}{\sqrt{p_i(1 - p_i)}}. \quad (2.41)$$

Такое преобразование позволяет измерить степень уверенности модели относительно случайного прогноза. Чем дальше вероятность от 0.5, тем выше абсолютное значение z_i .

Дальше размер позиции определялся по формуле:

$$m_i = 2\Phi(z_i) - 1, \quad (2.42)$$

где $\Phi(z)$ — функция распределения стандартного нормального закона.

В результате размер позиции принимал значения из интервала:

$$m_i \in [-1, 1]. \quad (2.43)$$

Если вероятность модели была близка к 0.5, размер позиции оказывался близким к нулю. Это означало, что модель не обладает достаточной уверенностью и позиция должна быть небольшой. При высоких вероятностях размер позиции увеличивался.

Итоговая позиция определялась как произведение направления сделки и confidence score:

$$position_i = side_i \cdot m_i, \quad (2.44)$$

где $side_i$ задавался первичной momentum-моделью.

Базовая версия probability-based bet sizing оказалась достаточно консервативной, поскольку большинство вероятностей находились относительно близко к 0.5. Поэтому дополнительно исследовались более уверенные варианты определения объема позиции. Для этого z-score умножался на коэффициент уверенности α :

$$z_i^{conf} = \alpha z_i. \quad (2.45)$$

При увеличении α стратегия открывала более крупные позиции при тех же вероятностях модели.

3. Данные и их подготовка

3.1. Финансовые активы

В работе используются ETF, представляющие различные классы активов финансового рынка США. Такой выбор позволяет исследовать устойчивость методов машинного обучения в различных рыночных режимах и на активах с различной природой риска.

В исследование включены следующие инструменты:

- SPY — ETF на индекс S&P 500
- QQQ — ETF на индекс NASDAQ-100
- TLT — долгосрочные государственные облигации США
- GLD — золото
- DBC — товарный рынок
- EEM — акции развивающихся стран
- IYR — рынок недвижимости США

- UUP — индекс доллара США

Исторические данные по ETF были получены с использованием библиотеки `yfinance`. Для каждого инструмента использовались цены закрытия и торговые объёмы.

3.2. Макроэкономические и рыночные индикаторы

Помимо ценовых данных в модель включались макроэкономические и рыночные индикаторы, отражающие состояние финансовой системы, инфляционные ожидания и уровень неопределённости.

Часть данных была получена через API Federal Reserve Economic Data (FRED). Использовались следующие показатели:

- доходности государственных облигаций США
- credit spreads
- ставка федеральных фондов
- инфляционные показатели CPI и PCE
- уровень безработицы
- промышленное производство
- индекс финансового стресса STLFSI
- breakeven inflation rates

Дополнительно использовались рыночные индикаторы:

- индекс волатильности VIX
- индекс облигационной волатильности MOVE
- индекс доллара DXY
- цены нефти Brent и WTI
- цены природного газа

- цены меди

Дополнительно в модель были включены индексы неопределённости и геополитического риска:

- GPRD — дневной индекс геополитического риска
- TPU — индекс неопределённости торговой политики
- EPU — индекс экономической политической неопределённости
- WUI — мировой индекс неопределённости

Эти индикаторы использовались для учёта внешней неопределённости, которая может влиять на поведение инвесторов, волатильность активов и устойчивость momentum-сигналов.

3.3. Momentum-признаки

Momentum-признаки отражают динамику изменения цены за различные временные интервалы:

$$mom_w(t) = \frac{P_t}{P_{t-w}} - 1, \quad (3.1)$$

где w — размер окна.

В работе использовались окна:

- 5 дней
- 21 день
- 63 дня
- 252 дня

3.4. Volatility-признаки

Для оценки изменчивости рынка рассчитывалась реализованная волатильность:

$$\sigma_t = \sqrt{\frac{1}{w} \sum_{i=1}^w (r_{t-i} - \bar{r})^2}. \quad (3.2)$$

Также использовались отношения краткосрочной и долгосрочной волатильности, позволяющие оценивать изменение рыночного режима.

3.5. Признаки максимальной просадки

Дополнительно рассчитывались признаки максимальной просадки:

$$DD_t = \frac{P_t - \max(P_{t-w}, \dots, P_t)}{\max(P_{t-w}, \dots, P_t)}. \quad (3.3)$$

Эти признаки отражают силу локального падения рынка и позволяют учитывать асимметрию поведения доходностей.

3.6. Итоговая подготовка данных

После загрузки исходных данных все ряды были приведены к единой дневной временной шкале. Для этого использовался общий календарь торговых дней ETF. Ряды с меньшей частотой наблюдений, например месячные и квартальные макроэкономические показатели, переносились вперёд до появления нового значения.

Ценовые ряды ETF были преобразованы в логарифмы цен, после чего к ним применялось дробное дифференцирование. Это позволило снизить нестационарность рядов и при этом сохранить часть долгосрочной памяти. Аналогичная процедура применялась к ценоподобным рыночным индикаторам, таким как индекс доллара, цены нефти, природного газа и меди.

Для макроэкономических переменных использовались преобразования, соответствующие экономическому смыслу показателей. Для уровневых рядов рассчитывались изменения, темпы роста или годовые изменения. Например, для индексов цен использовались показатели инфляции, а для части макроэкономических индикаторов — первые разности или изменения относительно предыдущего периода.

4. Методология исследования

В этом разделе описывается практическая реализация исследования. Теоретические элементы методологии были рассмотрены в предыдущем разделе, поэтому здесь приводятся только основные параметры эксперимента.

4.1. Формирование событий и целевой переменной

Для каждого ETF события формировались с помощью CUSUM-фильтра, применённого к дробно-дифференцированному ценовому ряду. Порог рассчитывался отдельно для каждого инструмента как одно стандартное отклонение дневного изменения FFD-ряда. Иными словами, в работе использовалось значение $\lambda = 1$.

После выделения событий применялся Triple Barrier Method. Вертикальный барьер составлял 5 торговых дней. В качестве первичной модели использовался momentum за 63 торговых дня:

$$side_t = sign(mom_{63,t}). \quad (4.1)$$

Если momentum был положительным, задавалась длинная позиция, если отрицательным — короткая. Горизонтальные барьеры задавались параметрами $ptSl = [1, 2]$: верхний барьер находился на расстоянии одной оценки волатильности, нижний — на расстоянии двух оценок волатильности.

Итоговая целевая переменная строилась как бинарная meta-labeling метка. Если сделка с учётом направления первичного сигнала давала положительную доходность, событию присваивался класс 1. Если доходность была неположительной, присваивался класс 0.

4.2. Обучение моделей

Для каждого ETF отдельно обучались три модели:

- Logistic Regression
- RandomForest
- LightGBM

Перед обучением выполнялся отбор признаков методом Single Feature Importance. Для каждой модели использовались веса наблюдений, учитывающие пересечение событий во времени и приписанную доходность. Веса передавались в модели через параметр `sample_weight`.

Гиперпараметры подбирались только на обучающей выборке. Для Logistic Regression использовался GridSearchCV, для RandomForest и LightGBM — RandomizedSearchCV. Во всех случаях применялась очищенная кросс-валидация PurgedKFold с параметрами:

$$n_{splits} = 3, \quad pctEmbargo = 0.02. \quad (4.2)$$

Основной метрикой подбора гиперпараметров являлась $F1_{macro}$. Эта метрика была выбрана потому, что она учитывает качество распознавания обоих классов и не позволяет модели получать высокую оценку за счёт постоянного предсказания класса 1.

4.3. Размер позиции

После обучения модель выдавала вероятность успешности сигнала:

$$p_i = P(y_i = 1 \mid X_i). \quad (4.3)$$

Эта вероятность использовалась для определения размера позиции. Сначала вероятность преобразовывалась в z-score, затем размер позиции рассчитывался по формуле probability-based bet sizing:

$$m_i = 2\Phi(z_i) - 1. \quad (4.4)$$

Итоговая позиция определялась с учётом направления первичной модели:

$$position_i = side_i \cdot m_i. \quad (4.5)$$

Кроме базового варианта ML_z_bet дополнительно тестировались более уверенные версии стратегии. Для этого z-score умножался на коэффициент α . В работе сравнивались варианты $\alpha = 1.5$, $\alpha = 2$ и $\alpha = 3$, которые обозначены как ML_conf_15 , ML_conf_20 и ML_conf_30 .

4.4. Walk-forward backtesting

Финальная проверка проводилась на тестовой выборке с использованием walk-forward backtesting. Использовалась расширяющаяся схема обучения: для каждого тестового события модель обучалась только на событиях, которые были полностью известны к моменту прогноза.

Выбранная модель, набор признаков и гиперпараметры фиксировались заранее на обучающей выборке. В walk-forward тестировании они не подбирались заново, чтобы избежать использования будущей информации.

Количество тестовых событий различалось по ETF:

Таблица 1 — Количество тестовых событий в walk-forward backtesting

ETF	Число тестовых событий
SPY	186
QQQ	242
TLT	306
GLD	278
EEM	171
DBC	245
IYR	144
UUP	261

ML-стратегии сравнивались с базовыми стратегиями Momentum63 и Momentum21. Финансовые результаты оценивались по годовой доходности, Sharpe ratio, максимальной просадке, hit ratio и среднему размеру позиции.

5. Результаты исследования

5.1. Результаты моделей машинного обучения

На первом этапе оценивалось качество моделей meta-labeling. Для каждого ETF отдельно обучались Logistic Regression, RandomForest и LightGBM. В таблице 2 представлены лучшие ML-модели по каждому инструменту.

Таблица 2 — Лучшие модели meta-labeling по ETF

ETF	Модель	$F1_{macro}$	$F1$	Accuracy	Precision ₁	Recall ₁
SPY	RF	0.5575	0.6058	0.5628	0.5938	0.6183
QQQ	RF	0.5452	0.6471	0.5680	0.6046	0.6960
TLT	LGBM	0.5055	0.5638	0.5124	0.5412	0.5883
GLD	LR	0.5369	0.6227	0.5528	0.5475	0.7220
EEM	RF	0.5321	0.6035	0.5430	0.5673	0.6447
DBC	LGBM	0.5472	0.5842	0.5502	0.6006	0.5686
IYR	RF	0.5296	0.6266	0.5496	0.5765	0.6862
UUP	LGBM	0.5540	0.6446	0.5724	0.6017	0.6941

Результаты показывают, что качество классификации остаётся умеренным. Значения $F1_{macro}$ находятся примерно в диапазоне от 0.51 до 0.56. Для финансовых данных это является ожидаемым результатом, поскольку доходности обладают низким отношением сигнал/шум. При этом лучшие ML-модели превосходят случайный классификатор по $F1_{macro}$ (у случайного классификатора значение метрики равно 0.5).

Особенно важно, что использование $F1_{macro}$ позволило избежать ситуации, когда модель почти всегда предсказывает класс 1. Такая проблема возникала при оптимизации обычной F1-меры, поскольку класс 1 соответствует успешной сделке и обычная F1-мера не штрафует модель за плохое распознавание класса 0. Поэтому в итоговой версии основное внимание уделялось более сбалансированному качеству классификации.

По типам моделей результаты оказались неоднородными. RandomForest стал лучшей моделью для SPY, QQQ, EEM и IYR. LightGBM оказался лучшим для TLT, DBC и UUP. Logistic Regression дала лучший результат для GLD. Это показывает, что универсально лучшей модели для всех ETF не существует, а предсказательная структура различается между классами активов.

5.2. Финансовые результаты базовой ML-стратегии

После оценки качества классификации модели были протестированы в walk-forward backtesting. В таблице 3 сравниваются базовая ML-стратегия с z-test bet sizing и две momentum-стратегии.

Следует отметить, что в работе сравнение стратегий проводится на уровне событий. События формируются с помощью CUSUM-фильтра и возникают неравномерно во времени, поэтому стандартные финансовые метрики могут интерпретироваться только как приближённые оценки. В частности, показатели годовой доходности и Sharpe ratio рассчитываются по последовательности событий, а не по непрерывному временному ряду доходностей портфеля.

По этой причине основной акцент делается не на абсолютных значениях годовых метрик, а на сравнительном анализе поведения стратегий: hit ratio, относительной устойчивости, средней величине позиции и способности ML-модели снижать риск неудачных сигналов.

Таблица 3 — Финансовые результаты ML z-test и momentum-стратегий

ETF	Стратегия	Ann. ret	Sharpe	Max DD	Hit ratio	Avg bet
SPY	ML z-test	0.0662	1.6755	-0.0274	0.3978	0.1040
SPY	Momentum63	0.7814	1.9870	-0.2885	0.6344	1.0000
SPY	Momentum21	0.3581	1.1232	-0.2356	0.5860	1.0000
QQQ	ML z-test	0.1224	1.4623	-0.0812	0.4587	0.1686
QQQ	Momentum63	0.4664	1.1481	-0.4165	0.6074	1.0000
QQQ	Momentum21	0.2498	0.7527	-0.3377	0.5455	1.0000
DBC	ML z-test	0.1501	1.5729	-0.0974	0.3469	0.1774
DBC	Momentum63	0.1626	0.6331	-0.4974	0.5551	1.0000
DBC	Momentum21	-0.0896	-0.1360	-0.5178	0.5184	1.0000
GLD	ML z-test	0.1056	0.5512	-0.2127	0.5180	0.3635
GLD	Momentum63	1.1521	2.1265	-0.2554	0.6223	1.0000
GLD	Momentum21	-0.0026	0.1955	-0.4512	0.5180	1.0000
EEM	ML z-test	0.0700	1.0838	-0.0386	0.3626	0.1350
EEM	Momentum63	-0.2635	-0.7003	-0.4213	0.5439	1.0000
EEM	Momentum21	0.2378	0.7847	-0.2450	0.5146	1.0000
IYR	ML z-test	-0.0191	-0.2668	-0.0520	0.2847	0.0967
IYR	Momentum63	-0.2132	-0.4936	-0.2865	0.5069	1.0000
IYR	Momentum21	-0.6051	-2.4540	-0.4874	0.4444	1.0000
TLT	ML z-test	-0.0050	-0.0274	-0.0837	0.2582	0.1439
TLT	Momentum63	-0.3571	-1.3787	-0.4683	0.4837	1.0000
TLT	Momentum21	-0.1779	-0.5290	-0.3118	0.5131	1.0000
UUP	ML z-test	-0.0363	-1.2895	-0.0468	0.3065	0.1552
UUP	Momentum63	-0.0575	-0.3695	-0.1337	0.4981	1.0000
UUP	Momentum21	0.0448	0.3909	-0.1623	0.5057	1.0000

Результаты показывают, что ML-стратегия не всегда превосходит momentum-подход по абсолютной доходности, но во многих случаях meta-labeling позволяет существенно снизить риск и уменьшить глубину просадки.

Для SPY и QQQ momentum-стратегии показывают более высокую ито-

говую доходность, но сопровождаются значительно более высокой просадкой. Например, для SPY максимальная просадка Momentum63 составила около -28% , тогда как для ML z-test она оставалась около -3% . Аналогичная картина наблюдается для QQQ и DBC.

Особенно интересным выглядит результат для DBC. Несмотря на близкие значения доходности между ML z-test и Momentum63, ML-подход демонстрирует значительно более устойчивое поведение и существенно меньшую просадку.

Для части ETF, например GLD и SPY, базовый momentum остаётся сильным сигналом, и ML-фильтрация снижает агрессивность стратегии. Однако для более нестабильных активов meta-labeling помогает уменьшать влияние неудачных сигналов и улучшать риск-профиль стратегии.

5.3. Влияние масштабирования уверенности

Базовая версия ML z-test оказалась достаточно консервативной, поскольку средний размер позиции оставался относительно небольшим. Поэтому дополнительно были протестированы более агрессивные варианты bet sizing, в которых z-score вероятности умножался на коэффициент уверенности α .

Следует учитывать, что приведённые показатели также относятся к event-level сравнению стратегий и не являются полноценной portfolio-level оценкой.

Таблица 4 — Влияние confidence scaling на ML-стратегии

ETF	Стратегия	Ann. ret	Sharpe	Max DD	Avg bet
SPY	ML z-test	0.0662	1.6755	-0.0274	0.1040
SPY	ML conf 15	0.0957	1.6490	-0.0406	0.1498
SPY	ML conf 20	0.1212	1.6112	-0.0532	0.1901
SPY	ML conf 30	0.1589	1.5147	-0.0765	0.2551
QQQ	ML z-test	0.1224	1.4623	-0.0812	0.1686
QQQ	ML conf 15	0.1662	1.4084	-0.1179	0.2358
QQQ	ML conf 20	0.2001	1.3664	-0.1482	0.2910
QQQ	ML conf 30	0.2542	1.3414	-0.1875	0.3736
DBC	ML z-test	0.1501	1.5729	-0.0974	0.1774
DBC	ML conf 15	0.1775	1.4301	-0.1372	0.2398
DBC	ML conf 20	0.1773	1.2461	-0.1738	0.2873
DBC	ML conf 30	0.1453	0.9052	-0.2366	0.3548
GLD	ML z-test	0.1056	0.5512	-0.2127	0.3635
GLD	ML conf 15	0.1916	0.7585	-0.2536	0.4703
GLD	ML conf 20	0.2916	0.9719	-0.2726	0.5430
GLD	ML conf 30	0.4631	1.2926	-0.2788	0.6302
EEM	ML z-test	0.0700	1.0838	-0.0386	0.1350
EEM	ML conf 15	0.0999	1.1122	-0.0540	0.1912
EEM	ML conf 20	0.1280	1.1563	-0.0675	0.2389
EEM	ML conf 30	0.1740	1.2237	-0.0912	0.3129
IYR	ML z-test	-0.0191	-0.2668	-0.0520	0.0967
IYR	ML conf 15	-0.0311	-0.3020	-0.0719	0.1382
IYR	ML conf 20	-0.0453	-0.3553	-0.0887	0.1741
IYR	ML conf 30	-0.0792	-0.4949	-0.1145	0.2312

Результаты показывают, что увеличение коэффициента α практически всегда приводит к росту среднего размера позиции. Одновременно возрастает как потенциальная доходность стратегии, так и её риск.

Для большинства ETF более агрессивные версии confidence scaling сопровождаются увеличением просадки. Особенно заметно это для SPY, QQQ

и DBC.

При этом эффект scaling различается между активами. Для GLD и EEM увеличение α приводило не только к росту доходности, но и к улучшению risk-adjusted характеристик стратегии. Для DBC, наоборот, слишком агрессивный scaling ухудшал устойчивость результатов.

В целом результаты показывают, что вероятности meta-labeling модели могут использоваться не только для бинарного решения о входе в сделку, но и как инструмент адаптивного управления размером позиции.

6. Ограничения исследования

У работы есть несколько ограничений.

Во-первых, главное ограничение связано с интерпретацией финансовых результатов. В работе стратегии сравниваются преимущественно на уровне отдельных событий, сформированных CUSUM-фильтром. Такой подход позволяет оценить качество сигналов и работу meta-labeling, но не является полноценной симуляцией инвестиционного портфеля. События возникают неравномерно во времени, а позиции могут пересекаться. Поэтому показатели годовой доходности, коэффициента Шарпа и максимальной просадки следует рассматривать только как приближённые сравнительные характеристики внутри этого исследования. Их нельзя напрямую интерпретировать как реальные показатели доходности и риска торговой стратегии.

Во-вторых, исследование основано на дневных данных. Использование более частых данных могло бы увеличить число наблюдений и позволить точнее анализировать динамику сигналов.

В-третьих, в работе не учитывались комиссии, спред между ценой покупки и продажи и проскальзывание. Для практического применения стратегии эти факторы могут существенно снизить итоговую доходность, особенно если средняя доходность отдельной сделки невелика.

В-четвертых, набор признаков ограничен техническими, межрыночными и макроэкономическими переменными.

7. Заключение

В работе была исследована применимость методов Financial Machine Learning к задаче фильтрации инвестиционных сигналов на рынке ETF. В качестве базовой стратегии использовался momentum-подход, а модели машинного обучения применялись в рамках meta-labeling для определения того, какие сигналы следует принимать.

В ходе исследования были реализованы CUSUM-фильтр, Triple Barrier Method, Fractional Differentiation, взвешивание наблюдений, PurgedKFold с embargo, отбор признаков, обучение моделей Logistic Regression, RandomForest и LightGBM, а также walk-forward backtesting.

Полученные результаты показывают, что модели машинного обучения обладают умеренной предсказательной способностью.

С практической точки зрения meta-labeling оказался наиболее полезен как инструмент фильтрации рискованных сигналов и управления размером позиции. Для части ETF ML-подход позволял уменьшать просадки и сглаживать траекторию капитала по сравнению с базовыми momentum-стратегиями.

Дополнительный анализ confidence scaling показал, что вероятность модели может использоваться не только для бинарного решения о входе в сделку, но и для адаптивного определения размера позиции.

Следует учитывать, что финансовые результаты в работе анализировались преимущественно на уровне событий. Поэтому полученные значения следует интерпретировать как сравнительные характеристики внутри исследования, а не как точную оценку реальной торговой стратегии.

Главный вывод работы состоит в том, что методы Financial Machine Learning наиболее полезны не как инструмент точного прогнозирования рынка, а как механизм фильтрации сигналов, контроля риска и управления позицией.

Список литературы

- [1] López de Prado M. Advances in Financial Machine Learning. Wiley, 2018.