Сапунков С.Н., Горячкин В.К., Герцен Р.А., Красникова А.П., Латышова Е.О.

Моделирование доходности золота

В работе исследуется задача прогнозирования доходности золота с использованием методов машинного обучения. Сравниваются различные модели прогнозирования логарифмической доходности и анализируется их способность генерировать устойчивые торговые сигналы. Для повышения стабильности прогнозов используется нормализация сигналов на основе стохастического моделирования волатильности ошибок, а полученные стратегии объединяются в портфель в рамках подхода, близкого к портфельной теории Марковица. Результаты показывают, что комбинация методов машинного обучения, стохастических процессов и портфельной агрегации сигналов позволяет существенно повысить устойчивость и риск-скорректированную доходность стратегии.

1. Введение

Золото является одним из древнейших финансовых активов и используется в качестве средства накопления стоимости на протяжении нескольких тысячелетий. Исторические источники свидетельствуют о том, что золото рассматривалось как драгоценный металл и средство хранения богатства уже в цивилизациях Древнего Египта и Ближнего Востока около 3000 года до н.э.[1]

В современной финансовой системе золото остаётся одним из наиболее ликвидных драгоценных металлов и важным элементом глобальных рынков капитала. Рынок золота глубоко интегрирован в финансовую инфраструктуру и включает широкий спектр инструментов – от физического металла до фьючерсов, опционов и биржевых фондов (ETF). Совокупный объём добытого за всю историю золота превышает 200 тыс. тонн, что соответствует рыночной стоимости в десятки триллионов долларов США.[2]

[1] World Gold Council. *The history of gold*. https://www.gold.org

[2] World Gold Council. *Above-ground stocks of gold*. https://www.gold.org

Значительная часть ценовой динамики формируется на рынке производных инструментов, прежде всего на бирже COMEX, входящей в CME Group, где сосредоточена значительная доля мировой торговли золотыми фьючерсами.[3]

Динамика доходности золота представляет практический интерес для различных категорий участников рынка. Центральные банки используют золото в структуре международных резервов, институциональные инвесторы применяют модели доходности и волатильности для построения торговых стратегий и управления рисками, а золотодобывающие компании используют прогнозы цен для планирования инвестиций и хеджирования.

В настоящей работе рассматривается задача моделирования логарифмической доходности спотовой цены золота. Использование логарифмической доходности является стандартным подходом в финансовой эконометрике, поскольку такие доходности обладают рядом удобных свойств, включая аддитивность во времени и удобство применения в моделях временных рядов (Campbell et al., 1997). Целью исследования является разработка торговой стратегии на рынке золота, основанной на моделях машинного обучения и направленной на получение устойчивой положительной альфы. В рамках работы прогнозирование логарифмической доходности используется как инструмент для формирования торговых сигналов и последующей оценки эффективности стратегии.

Структура исследования организована следующим образом. В разделе 2 описаны используемые данные и процедура отбора признаков. В разделе 3 представлены используемые модели и процесс их обучения. В разделе 4 рассматриваются методы моделирования волатильности и формализуются правила построения торговых сигналов. В разделе 5 описана процедура формирования портфеля и приведены результаты бэктестирования. В разделе 6 обсуждаются основные выводы исследования и его ограничения.

2. Обзор Литературы

Золото традиционно рассматривается как защитный актив и средство хеджирования рисков в периоды экономической и финансовой нестабильности. В связи с этим значительное число работ посвящено анализу факторов, определяющих динамику цен золота и его доходности. В частности, исследования показывают, что золото тесно связано с динамикой других товарных рынков, финансовых активов и макроэкономических факторов (Kang et al., 2017).

Одним из важных направлений исследований является анализ влияния рыночной неопределённости и финансовой волатильности на цены золота. В качестве индикатора глобальной рыночной неопределённости часто используется индекс волатильности VIX. Повышение значения VIX обычно сопровождается ростом спроса на защитные

[3] CME Group. *Gold Futures Market Data*. https://www.cmegroup.com

активы, поскольку инвесторы стремятся сократить экспозицию к рискованным активам и увеличить долю более надежных инструментов. В результате золото часто демонстрирует положительную реакцию на рост рыночной волатильности. Аналогичную роль играет неопределенность экономической политики, измеряемая индексом Economic Policy Uncertainty (EPU). Рост данного индекса отражает повышение неопределенности экономической среды, что может приводить к увеличению спроса на активы-убежища, включая золото (You et al., 2025).

Для анализа динамики финансовых временных рядов широко используется представление доходностей в виде логарифмических доходностей. Использование логарифмических доходностей является стандартным подходом в финансовой эконометрике и количественных финансовых исследованиях, поскольку такие доходности обладают рядом удобных свойств, включая аддитивность во времени и более стабильные статистические характеристики по сравнению с простыми доходностями. Благодаря этим свойствам логарифмические доходности широко применяются при построении моделей финансовых временных рядов и алгоритмов машинного обучения для прогнозирования цен активов (de Prado, 2018).

При анализе взаимосвязей между финансовыми переменными часто используются методы корреляционного анализа. В частности, ранговая корреляция Спирмена позволяет выявлять монотонные зависимости между переменными без предположения о нормальности распределения данных.

Традиционные методы прогнозирования финансовых временных рядов основаны преимущественно на линейных статистических моделях, таких как модели авторегрессии и интегрированного скользящего среднего (ARIMA). Однако данные методы способны описывать лишь линейные зависимости между переменными. Комбинирование ARIMA-моделей с нейронными сетями позволяет существенно улучшить качество прогнозирования временных рядов за счет возможности моделирования нелинейных зависимостей (Zhang, 2003).

С развитием вычислительных методов и ростом доступности данных все более широкое распространение получили методы машинного обучения. Благодаря способности выявлять сложные нелинейные зависимости и учитывать взаимодействия между большим числом признаков, такие методы демонстрируют высокую эффективность при анализе финансовых данных (Liu & Li, 2017).

Однако применение методов машинного обучения в задачах финансового прогнозирования связано с риском переобучения, особенно при использовании большого числа признаков. Для снижения данного риска широко применяются методы регуляризации. К числу наиболее распространённых относятся Ridge- и Lasso-регрессии, которые позволяют контролировать величину коэффициентов модели и тем самым уменьшать вероятность переобучения.

Современные исследования также активно используют ансамблевые методы машинного обучения. К наиболее распространённым алгоритмам относятся случайный лес (Random Forest) и методы градиентного бустинга, включая XGBoost, LightGBM и CatBoost. Эти алгоритмы демонстрируют высокую эффективность при прогнозировании финансовых временных рядов благодаря способности выявлять сложные нелинейные зависимости между признаками и целевой переменной, а также устойчивости к шуму в данных.

3. Данные

Для анализа используются рыночные и макрофинансовые временные ряды, отражающие ключевые факторы, влияющие на динамику золота: товарные рынки, глобальные рисковые активы, процентные ставки, валюты, показатели рыночной волатильности, структуру срочного рынка и позиционирование участников. Блок товарных рынков включает котировки золота, серебра, нефти WTI и меди. Для большинства инструментов используются стандартные дневные рыночные показатели (open, close, high, low), что позволяет учитывать внутридневную ценовую динамику. Для учета глобального аппетита к риску используются котировки индекса S&P 500 и объёмы торгов. Отдельно стоит отметить, что в период с 2022 года начался резкий рост цен на золото, который не объясняется моделями прошлых лет, основанными на процентных ставках в США и ожидаемой инфляции. Такой тесной взаимосвязи между ценами золота и этими фундаментальными факторами, которая была раньше, в последние годы не наблюдается. Кроме того, цель – выстроить инвестиционную стратегию на короткий горизонт. Для этой задачи лучше всего подходят методы машинного обучения, поэтому для их применения помимо фундаментальных переменных были взяты и переменные, которые обычно используются в ML моделях для прогнозирования доходности металлов. Факторы системного риска представлены индексами волатильности VIX, MOVE и GVZ, а также индексом геополитической неопределенности EPU. VIX, MOVE и GVZ– индексы, отражающие ожидаемую волатильность индекса S&P 500, казначейских облигаций США и золота соответственно на основании фьючерсной кривой. Они являются маркерами рыночных настроений и часто используются в прогнозировании золота, поскольку последнее с зачастую воспринимается инвесторами как защитный актив. EPU является индексом политической неопределённости EPU в США и рассчитывается на основе анализа сентимента. Облигации США традиционно считались альтернативой золоту, поэтому также были включены в регрессию (однолетние– 1Y и десятилетние 10 Y, десятилетние были взяты и с фиксированным номиналом, а также индексируемые на инфляцию TIPS). Ожидаемая инфляция была представлена показателем “Breakeven inflation”, рассчитанным как спред между индексируемыми на инфляцию и неиндекси-

руемыми облигациями. Именно этот показатель является лучшей прокси инфляционных ожиданий на дневной частоте. Также для учёта настроений на долговом рынке был использован индекс “ICE BofA US HighYield Index Option Adjusted Spread (OAS)”. Это средневзвешенный спред между высокодоходными облигациями и гособлигациями США. Его увеличение при прочих равных означает ожидание кризисных явлений в экономике США.

Для учета валютного канала используются индекс доллара DXY и валютные пары EUR/USD и JPY/USD. Поскольку золото номинировано в долларах США, динамика доллара является одним из ключевых драйверов его доходности.

Также учитывается информация срочного рынка золота: котировки ближайших фьючерсных контрактов, объёмы торгов, открытый интерес и количество дней до экспирации. Эти переменные отражают структуру терм кривой и активность рынка деривативов. Наконец, используются данные позиционирования участников рынка из отчетов Commitments of Traders (CFTC), включая чистые позиции коммерческих участников, управляющих активами (Money Managers), своп-дилеров и мелких спекулянтов, которые могут отражать рыночные ожидания и настроения участников рынка. Большинство рядов имеют дневную частоту наблюдений, тогда как данные CFTC публикуются еженедельно. Подробное описание всех переменных приведено в Таблице 5 в Приложении А.

В качестве объекта исследования используется спотовая цена золота. Основная цель работы заключается в сравнении различных методов моделирования и прогнозирования доходности, поэтому в качестве базового актива выбран относительно простой и высоколиквидный инструмент. Спотовая цена золота является ключевым бенчмарком для всего рынка и тесно связана с динамикой крупнейших инвестиционных инструментов на золото, включая ETF.

Выборка начинается с 2010 года. Такой период позволяет сосредоточиться на посткризисной структуре финансовых рынков, сформировавшейся после глобального финансового кризиса 2008–2009 годов. Это решение позволяет снизить влияние структурных разрывов и экстремальных шоков кризисного периода, сосредоточив анализ на более однородной фазе развития рынков.

Целевая переменная формировалась как логарифмическая доходность спотовой цены золота на различных горизонтах прогнозирования. Для горизонта h целевая переменная задавалась как

$$r_{t,h} = \log\left(\frac{P_{t+h}}{P_t}\right),$$

где P_t – спотовая цена золота в момент времени t. В работе рассматривался набор горизонтов от 1 до 70 торговых дней.

Блоки факторов

Генерация признаков строилась по принципу экономической интерпретируемости. Исходные переменные были разделены на несколько классов факторов, отражающих различные каналы формирования цены золота.

Блок факторов	Экономическая интерпретация
Ценовые ряды	Динамика сырьевых и финансовых активов (золото, серебро, нефть, медь, BTC, FX, индексы).
OHLC-признаки	Внутридневная структура движения цен: диапазон, разрыв открытия, положение закрытия.
Макрофинансовые уровни	Процентные ставки, инфляционные ожидания, кредитные спреды.
Объёмы и ликвидность	Торговая активность и распределение ликвидности на рынках.
Относительные спрэды	Положение золота относительно других активов и рынков.
Срочная кривая золота	Форма фьючерсной кривой, basis и структура контанго/бэквордации.
Позиционирование CFTC	Баланс хеджеров и спекулятивного капитала.
Кросс-активные взаимодействия	Совместная динамика золота с ключевыми макрофакторами.
Календарные эффекты	Сезонность и календарная структура торговых дней.

Построение признаков

Для каждого блока применялись стандартные преобразования временных рядов, широко используемые в количественных моделях.

Для ценовых рядов рассчитывались лаговые логарифмические доходности

$$r_t^{(k)} = \log\left(\frac{P_t}{P_{t-k}}\right),$$

а также отклонения цены от скользящих средних, реализованная волатильность, средние доходности и относительное положение цены внутри rolling-диапазона.

Для уровневых макроэкономических переменных использовались изменения уровней

$$\Delta x_t^{(k)} = x_t - x_{t-k},$$

а также rolling z-score[4]

$$z_t = \frac{x_t - \mu_t}{\sigma_t},$$

где μ_t и σ_t – скользящее среднее и стандартное отклонение.

Для данных открытия, максимума, минимума и закрытия цены (OHLC) рассчитывались внутридневные характеристики движения цены, включая доходность между закрытием предыдущего дня и открытием текущего (close-to-open), ночной ценовой разрыв (overnight gap), диапазон между максимумом и минимумом (high-low) и положение цены закрытия внутри дневного диапазона.

Отдельный блок признаков описывал срочную кривую золота. Для каждого фьючерсного контракта рассчитывался basis

$$\text{basis}_t = \log\left(\frac{F_t}{S_t}\right),$$

а также annualized basis и наклон фьючерсной кривой. Эти показатели отражают ожидания рынка и структуру хеджирования.

Кроме того, строились относительные показатели между активами (например, gold/silver, gold/SPX, gold/DXY), а также rolling-корреляции и rolling-beta золота относительно других рынков.

Очистка признаков

После генерации признаков была проведена первичная очистка данных. На этом этапе:

- значения $\pm\infty$ заменялись на пропуски,
- удалялись признаки с высокой долей пропусков,
- удалялись признаки с практически нулевой дисперсией,
- исключались признаки с одной уникальной величиной.

Этот этап позволял устранить технически некорректные или неинформативные признаки.

Оценка информационного содержания признаков

Для каждого признака оценивалась его связь с целевыми переменными через ранговую корреляцию Спирмена (Information Coefficient).

Корреляция Спирмена определяется как

[4]Здесь и далее применяется rolling, поскольку данный метод позволяет избежать утечки данных

$$\rho_s = 1 - \frac{6 \sum d_i^2}{n(n^2 - 1)},$$

где d_i – разность рангов наблюдений.

Использование ранговой корреляции предпочтительно в данной задаче по двум причинам. Во-первых, она устойчива к выбросам и нелинейностям, которые характерны для финансовых временных рядов. Во-вторых, большинство торговых стратегий используют именно ранжирование сигналов, поэтому ранговая зависимость между признаком и будущей доходностью является более релевантной метрикой, чем линейная корреляция Пирсона.

Для каждого признака рассчитывалась средняя абсолютная величина IC по всем горизонтам прогнозирования. Признаки, не имеющие статистически значимой связи с таргетами, исключались.

Очистка от мультиколлинеарности

После оценки IC проводилась очистка от избыточных признаков. Строилась матрица попарных корреляций между признаками, и если два признака имели корреляцию выше 0.95, сохранялся только тот признак, который имел более высокий средний IC. Это позволяло снизить избыточность информации и уменьшить размерность признакового пространства.[5]

Walk-forward разбиение выборки

Для корректной оценки моделей использовалось временное walk-forward разбиение выборки. В каждом фолде использовались:

- около 9 лет данных для обучения,
- 1 год для валидации,
- 1 год для тестирования.

Между train, validation и test вводился временной разрыв, равный максимальному горизонту прогнозирования. Это исключало утечку информации из-за перекрывающихся доходностей.

Финальный отбор признаков

Внутри каждого train-фолда выполнялся основной pipeline отбора признаков. Для каждого признака рассчитывались следующие метрики:

- абсолютный in-sample IC – мера силы предсказательной связи;

[5] Вообще говоря, более эффективным подходом могло бы быть использование rolling PCA.

- t-stat IC с HAC-поправкой Newey-West – статистическая значимость сигнала с учетом автокорреляции и гетероскедастичности ошибок. Данная поправка важна, поскольку при прогнозировании n-дневной логарифмической доходности используется перекрывающаяся выборка, из-за чего $n - 1$ наблюдений в соседних доходностях совпадают, что может приводить к занижению стандартных ошибок;
- средний rolling IC на окнах 252 дня – средняя предсказательная способность сигнала во времени;
- стандартное отклонение rolling IC – устойчивость сигнала;
- доля rolling-окон, в которых знак IC совпадает с общим знаком сигнала – стабильность направления эффекта.

На основе этих метрик строился итоговый скоринг признака как взвешенная комбинация показателей качества.

После ранжирования признаков по score применялся дополнительный корреляционный фильтр: признаки добавлялись в итоговый список только если их корреляция с уже выбранными признаками была ниже 0.95. Таким образом формировался диверсифицированный набор факторов.

Для каждого горизонта прогнозирования и каждого временного фолда формировался итоговый набор из не более чем 200 признаков.

На последнем этапе для каждого прогнозного горизонта сохранялись таблицы метрик признаков и формировались отдельные наборы данных train/validation/test, содержащие только отобранные признаки. Эти наборы затем использовались для обучения и оценки моделей прогнозирования доходности золота. Сравнение ключевых метрик качества моделей для различных горизонтов прогнозирования приведено в Таблице 6 Приложения Б.

В качестве основной целевой переменной в дальнейшем анализе использовалась логарифмическая доходность золота на горизонте 10 торговых дней. Выбор данного горизонта был обусловлен результатами предварительного анализа линейных моделей: модель Elastic Net демонстрировала на этом горизонте наиболее устойчивые значения Information Coefficient (IC) и наилучшую стабильность out-of-sample прогнозов.

Отбор признаков для моделей на основе деревьев

Для моделей на основе деревьев решений (градиентный бустинг) использовался отдельный подход к отбору признаков. В отличие от линейных моделей, где естественной метрикой информативности является корреляция между признаком и целевой переменной, деревья и бустинговые алгоритмы способны эффективно выявлять нелинейные зависимости и взаимодействия между признаками. В связи с этим использование простой

корреляционной фильтрации может приводить к потере признаков, которые обладают слабой линейной связью с таргетом, но при этом оказываются полезными в нелинейной модели. По этой причине для бустинговых моделей применялся *model-based feature selection*.

Отбор признаков осуществлялся на основе модели градиентного бустинга *LightGBM*. Выбор данной модели обусловлен её способностью эффективно работать с большим числом признаков, автоматически выявлять нелинейные зависимости и строить сложные взаимодействия между факторами.

Процедура отбора проводилась в рамках walk-forward разбиения выборки. В каждом временном фолде данные разделялись на три части: обучающую выборку (примерно 9 лет), валидационную выборку (1 год) и тестовую выборку (1 год). Между блоками вводился временной разрыв, равный горизонту прогнозирования, что исключало утечку информации из-за перекрывающихся доходностей.

На каждом фолде обучалось несколько моделей LightGBM с различными значениями seed. Использование нескольких запусков позволяло уменьшить зависимость результатов от стохастических элементов алгоритма (subsampling наблюдений и признаков) и оценить устойчивость признаков.

После обучения модели для каждого признака извлекалась стандартная мера важности признака, основанная на *gain*. Данная метрика отражает суммарное улучшение функции потерь, полученное за счёт разбиений дерева по данному признаку. На этом этапе отбирался расширенный набор признаков с наибольшими значениями gain.

Далее применялась более строгая проверка информативности признаков с использованием permutation importance. Для каждого признака на валидационной выборке выполнялась случайная перестановка его значений, после чего модель заново строила прогноз. Качество прогноза измерялось через ранговую корреляцию Спирмена между прогнозом и фактической доходностью. Снижение IC после перестановки признака интерпретировалось как оценка его предсказательной значимости. Формально величина важности определялась как

$$\Delta IC = IC_{\text{base}} - IC_{\text{perm}},$$

где IC_{base} – значение корреляции Спирмена на исходных данных, а IC_{perm} – значение корреляции после случайной перестановки признака.

Таким образом, permutation importance измеряет вклад признака в способность модели правильно ранжировать будущие доходности.

Результаты отбора агрегировались по нескольким запускам модели внутри одного временного фолда. Для каждого признака вычислялась доля запусков, в которых он попадал в список выбранных факторов, а также медианное значение permutation importance. Признак сохранялся, если он демонстрировал устойчивую значимость и

появлялся в достаточной доле запусков модели.

После этого список признаков дополнительно ограничивался сверху, чтобы сформировать компактное множество факторов для обучения моделей.

На последнем этапе результаты агрегировались по всем временным фолдам. Для каждого признака оценивалась частота его отбора в различных периодах выборки. В итоговый набор включались только те признаки, которые демонстрировали устойчивую предсказательную способность на различных временных интервалах.

4. Модели

4.1. Линейные модели с регуляризацией

В данной работе для прогнозирования логарифмической доходности золота используются как методы машинного обучения на основе деревьев (Random Forest, XGBoost, LightGBM, CatBoost), так и линейные модели с регуляризацией (Ridge-регрессия, Lasso-регрессия, Elastic Net). Выбор линейных моделей обусловлен их способностью работать с высокоразмерными данными и устойчивостью к переобучению.

Ridge-регрессия

Ridge-регрессия (Hoerl, Kennard, 1970) использует L_2-регуляризацию. Штрафная функция в этом случае представляет собой сумму квадратов коэффициентов:

$$P_{\text{Ridge}}(\beta) = \sum_{j=1}^{p} \beta_j^2 = \|\beta\|_2^2. \tag{1}$$

Добавление L_2-штрафа приводит к тому, что модель минимизирует ошибку на обучающих данных, одновременно ограничивая величину коэффициентов. Это позволяет эффективно бороться с мультиколлинеарностью: если признаки сильно коррелированы, их коэффициенты распределяются между собой, что делает решение более устойчивым. При моделировании доходности золота Ridge-регрессия применяется в ситуациях, когда необходимо учитывать большое количество факторов, но при этом снизить чувствительность модели к шуму в данных.

Lasso-регрессия

Lasso-регрессия (Tibshirani, 1996) использует L_1-регуляризацию. Штрафная функция задаётся как сумма абсолютных значений коэффициентов:

$$P_{\text{Lasso}}(\beta) = \sum_{j=1}^{p} |\beta_j| = \|\beta\|_1. \tag{2}$$

В отличие от L_2-регуляризации, используемой в Ridge-регрессии, L_1-регуляризация способна обнулять неинформативные коэффициенты. Таким образом, Lasso одновре-

менно выполняет сжатие коэффициентов и отбор признаков. Это делает модель более интерпретируемой, поскольку в итоговой спецификации остаются только наиболее значимые регрессоры.

Elastic Net

Elastic Net (Zou, Hastie, 2005) представляет собой комбинацию L_1- и L_2-регуляризации. Штрафная функция включает оба компонента:

$$P_{\mathrm{EN}}(\beta) = \alpha \sum_{j=1}^{p} |\beta_j| + (1-\alpha) \sum_{j=1}^{p} \beta_j^2, \tag{3}$$

где $\alpha \in [0, 1]$ – параметр смешивания. При $\alpha = 1$ модель эквивалентна Lasso, при $\alpha = 0$ – Ridge. Промежуточные значения позволяют сочетать свойства обеих моделей: L_1-компонент способствует отбору значимых признаков, тогда как L_2-компонент стабилизирует решение при наличии коррелированных регрессоров.

Модели на основе деревьев решений

Помимо линейных моделей с регуляризацией, в работе используются методы машинного обучения на основе деревьев решений: Random Forest, XGBoost, LightGBM и CatBoost. Эти алгоритмы относятся к классу ансамблевых методов и позволяют моделировать нелинейные зависимости между признаками и целевой переменной. Это особенно важно для финансовых данных, где взаимосвязи между макроэкономическими индикаторами, сырьевыми рынками и доходностью активов часто имеют сложную нелинейную структуру.

Random Forest

Random Forest (Breiman, 2001) представляет собой ансамбль деревьев решений, обучаемых на различных подвыборках исходных данных. Каждое дерево строится на bootstrap-выборке обучающей выборки, а при каждом разбиении узла случайным образом выбирается подмножество признаков. Такой подход снижает корреляцию между деревьями и уменьшает переобучение.

Предсказание Random Forest формируется как среднее значение прогнозов отдельных деревьев:

$$\hat{y}(x) = \frac{1}{T} \sum_{t=1}^{T} f_t(x),$$

где T – количество деревьев, $f_t(x)$ – прогноз t-го дерева.

Благодаря усреднению большого числа деревьев модель обладает высокой устойчивостью к шуму в данных. В контексте прогнозирования доходности золота Random Forest позволяет учитывать нелинейные взаимодействия между различными факторами:

макроэкономическими показателями, сырьевыми активами и финансовыми индикаторами.

XGBoost

XGBoost (Chen, Guestrin, 2016) является алгоритмом градиентного бустинга над деревьями решений. В отличие от Random Forest, где деревья обучаются независимо, в бустинге каждое последующее дерево корректирует ошибки предыдущих моделей.

Модель строится как сумма прогнозов деревьев:

$$\hat{y}_i = \sum_{k=1}^{K} f_k(x_i),$$

где f_k – отдельное дерево решений.

Оптимизация осуществляется путем минимизации регуляризованной функции потерь:

$$L = \sum_{i=1}^{n} l(y_i, \hat{y}_i) + \sum_{k=1}^{K} \Omega(f_k),$$

где $l(\cdot)$ – функция потерь, а $\Omega(f_k)$ – регуляризационный штраф на сложность дерева.

Использование градиентного бустинга позволяет постепенно улучшать качество прогноза и эффективно моделировать сложные нелинейные зависимости в данных.

LightGBM

LightGBM (Ke et al., 2017) представляет собой оптимизированную реализацию градиентного бустинга над деревьями решений. Основным отличием алгоритма является использование стратегии роста деревьев типа leaf-wise, при которой расширяется тот лист, который обеспечивает наибольшее уменьшение функции потерь.

Такая стратегия позволяет быстрее снижать ошибку модели и строить более глубокие деревья при меньших вычислительных затратах. Кроме того, LightGBM использует представление признаков, при котором непрерывные признаки разделяются на конечное число интервалов (bins). Это позволяет существенно сократить число возможных разбиений при построении дерева и ускоряет процесс обучения модели.

Благодаря этим особенностям модель эффективно обрабатывает высокоразмерные датасеты и способна выявлять сложные нелинейные зависимости между признаками.

CatBoost

CatBoost (Prokhorenkova et al., 2018) является алгоритмом градиентного бустинга, разработанным специально для работы с табличными данными. Одной из ключевых особенностей CatBoost является использование ordered boosting, который позволяет уменьшить смещение прогнозов и снизить риск переобучения.

Подобно другим алгоритмам бустинга, итоговое предсказание формируется как сумма

прогнозов отдельных деревьев:

$$\hat{y}(x) = \sum_{k=1}^{K} f_k(x).$$

CatBoost хорошо работает на шумных табличных данных и способен эффективно моделировать сложные взаимодействия между признаками. В рамках данной работы модель продемонстрировала наилучшие значения информационного коэффициента (IC) среди рассмотренных алгоритмов машинного обучения.

Подбор гиперпараметров

Подбор гиперпараметров моделей осуществлялся на валидационной выборке с использованием байесовского алгоритма оптимизации, реализованного в библиотеке Optuna (Akiba, 2019). Данный подход позволяет эффективно исследовать пространство гиперпараметров и находить конфигурации, обеспечивающие наилучшее качество модели. В качестве целевой функции оптимизации использовался Information Coefficient (IC), рассчитываемый между прогнозируемыми и фактическими значениями доходности на валидационной выборке. Оптимизация проводилась таким образом, чтобы максимизировать значение данной метрики. Итоговые метрики качества моделей представлены в Таблице 7 в Приложении Б.

5. Построение торговой стратегии

Нормализация сигналов

Для учета временной изменчивости неопределенности прогнозов моделируется условная волатильность ошибок прогнозирования. Обозначим через

$$\varepsilon_{it} = y_t - \hat{y}_{it}$$

ошибку прогноза модели i в момент времени t.

Поскольку горизонт прогнозирования составляет 10 дней, последовательность ошибок формируется из перекрывающихся прогнозных окон. В результате девять из десяти наблюдений в соседних 10-дневных прогнозах совпадают, что создает значительную автокорреляцию в ряде ошибок. Для устранения этой проблемы условное среднее ошибок предварительно фильтруется с помощью процесса скользящего среднего.

Для моделей на основе деревьев решений и бустинга используется спецификация $MA(9)$, тогда как для линейных моделей применяется $MA(10)$. Такая спецификация позволяет адекватно описать автокорреляцию, возникающую из-за перекрывающихся горизонтов прогнозирования, и получить остатки, близкие к белому шуму.

После фильтрации условного среднего остатки модели $MA(q)$ используются для

оценки условной волатильности. Рассматриваются различные спецификации моделей семейства ARCH, включая GARCH, GJR-GARCH, EGARCH и FIGARCH. Для распределения ошибок допускаются распределения Стьюдента (t) и асимметричное распределение Стьюдента (skew-t).[6]

Выбор окончательной спецификации производится на основе информационных критериев (AIC, BIC), а также диагностических тестов на автокорреляцию и остаточную гетероскедастичность (тесты Ljung-Box и ARCH-LM). Итоговые спецификации моделей приведены в таблице 1.

Таблица 1: Выбранные спецификации моделей волатильности ошибок прогнозов

Модель	Спецификация
Random Forest	$MA(9)$ + FIGARCH$(1,1)$ - skew-t
CatBoost	$MA(9)$ + GJR-GARCH$(1,1)$ - skew-t
XGBoost	$MA(9)$ + FIGARCH$(1,1)$ - t
LightGBM	$MA(9)$ + GARCH$(1,1)$ - t
Ridge	$MA(10)$ + EGARCH$(3,3)$ - skew-t
Lasso	$MA(10)$ + EGARCH$(3,3)$ - skew-t
Elastic Net	$MA(10)$ + EGARCH$(2,3)$ - t

Используя выбранные спецификации, строится прогноз условной дисперсии ошибок на горизонте 10 шагов вперед. Обозначим через $\hat{\sigma}_{it}$ прогноз условного стандартного отклонения ошибки модели i в момент времени t. Тогда нормированный сигнал модели определяется как

$$Z_{it} = \frac{S_{it}}{\hat{\sigma}_{it}},$$

где S_{it} – исходный сигнал модели i.

Такая нормировка делает сигналы различных моделей сопоставимыми по масштабу и одновременно учитывает различия в надежности их прогнозов. Модели, для которых ошибки прогнозирования характеризуются высокой условной волатильностью, как правило, обладают более низкой предсказательной стабильностью. В контексте торговых стратегий это обычно приводит к более высокой изменчивости доходностей и, как следствие, к более низким значениям коэффициента Шарпа. Соответственно, масштабирование сигналов на прогноз условной волатильности ошибок уменьшает вклад менее стабильных моделей и повышает относительный вес моделей с более устойчивыми прогнозными свойствами.

[6]За идею использования GARCH-моделей для моделирования остатков автор выражает благодарность Кожиной А. А.

Выбор торговых порогов

Для каждой модели торговые пороги подбираются непосредственно по нормированному сигналу Z_{it} в рамках walk-forward процедуры. В отличие от подхода с квантильным правилом, здесь используются два независимых порога: $\theta_i^L \geq 0$ для открытия длинной позиции и $\theta_i^S \leq 0$ для открытия короткой позиции. Это позволяет учитывать возможную асимметрию предсказательной силы сигнала в положительной и отрицательной областях, когда модель может демонстрировать различную точность прогнозирования для длинных и коротких сигналов.

На каждом шаге walk-forward для модели i решается задача

$$(\hat{\theta}_{i,k}^L, \hat{\theta}_{i,k}^S) = \arg \max_{\theta^L, \theta^S \in \Theta} \mathrm{Sharpe}\big(\Pi_{i,t}(\theta^L, \theta^S)\big),$$

где $\Pi_{i,t}(\theta^L, \theta^S)$ обозначает временной ряд доходностей стратегии на обучающем окне, а Θ – дискретная сетка допустимых порогов. В расчетах используется равномерная сетка с шагом 0.1 в диапазоне

$$\theta^L \in [0, 3], \qquad \theta^S \in [-3, 0].$$

Оптимизация проводится на скользящем обучающем окне длиной 252 торговых дня, после чего найденные пороги фиксируются и применяются на последующем вневыборочном интервале длиной 21 торговый день. Далее окно сдвигается вперед, и процедура повторяется. Таким образом, пороги являются кусочно-постоянными функциями времени, адаптирующимися к текущему режиму рынка без использования информации из будущего.

Торговое правило

Для каждой модели i однодневный торговый слой определяется пороговым правилом

$$s_{it} = \begin{cases} 1, & Z_{it} > \theta_{it}^L, \\ -1, & Z_{it} < \theta_{it}^S, \\ 0, & \theta_{it}^S \leq Z_{it} \leq \theta_{it}^L. \end{cases}$$

Под *торговым слоем* понимается отдельная позиция, открываемая в момент времени t на основании сигнала модели и удерживаемая в течение фиксированного прогнозного горизонта. Каждый слой представляет собой независимую позицию, инициированную сигналом в конкретный день.

Поскольку прогнозный горизонт составляет $h = 10$ торговых дней, стратегия реализуется в виде перекрывающихся позиций. В каждый момент времени открывается новый торговый слой s_{it}, который затем удерживается в течение последующих h дней.

Совокупная позиция стратегии определяется как сумма всех активных слоев, открытых в предыдущие h дней:

$$q_{it} = \sum_{j=1}^{h} s_{i,t-j}, \qquad h = 10.$$

Тем самым в момент времени t агрегированная позиция отражает суммарную экспозицию всех ещё не закрытых слоев, инициированных сигналами в предыдущие дни. Такая конструкция согласована с природой 10-дневного прогнозного горизонта и корректно учитывает перекрытие последовательных торговых решений.

Обозначим через r_t фактическую дневную доходность актива. Тогда реализованная дневная доходность стратегии i задается как

$$R_{it} = q_{it} r_t.$$

Качество стратегии оценивается по вневыборочному коэффициенту Шарпа:

$$\text{Sharpe}_i = \frac{\mathbb{E}[R_{it}]}{\sqrt{\text{Var}(R_{it})}} \sqrt{252}.$$

Эта величина используется как критерий выбора как торговых порогов внутри walk-forward процедуры, так и лучшей модели среди альтернативных спецификаций.

Таблица 2 представляет вневыборочные характеристики торговых стратегий, построенных на основе различных моделей прогнозирования. Для каждой модели приведены коэффициент Шарпа, годовая доходность, годовая волатильность и максимальная просадка.

Таблица 2: Вневыборочные характеристики торговых стратегий

Модель	Sharpe	Return	Vol	MaxDD
CatBoost	1.950	16.7%	8.6%	-9.6%
Random Forest	1.769	15.5%	8.8%	-9.2%
Ridge	1.239	12.2%	9.8%	-11.8%
LightGBM	1.235	10.8%	8.7%	-12.3%
XGBoost	1.228	10.6%	8.6%	-9.6%
Lasso	1.130	12.0%	10.6%	-14.0%
Elastic Net	1.102	11.6%	10.5%	-14.1%
Mean	1.264	19.9%	15.7%	-21.3%
ARMA	0.952	11.3%	11.9%	-14.4%
Zero	-1.264	-19.9%	15.7%	-61.7%

Примечание: Mean – стратегия, использующая прогноз среднего значения доходности с лагом 10 дней; ARMA – стратегия на основе прогноза модели ARMA(2,4) с лагом 10 дней; Zero – наивная стратегия с нулевым прогнозом доходности. Для всех сратегий проводилась нормировка и подбор оптимальных параметров входа/выхода.

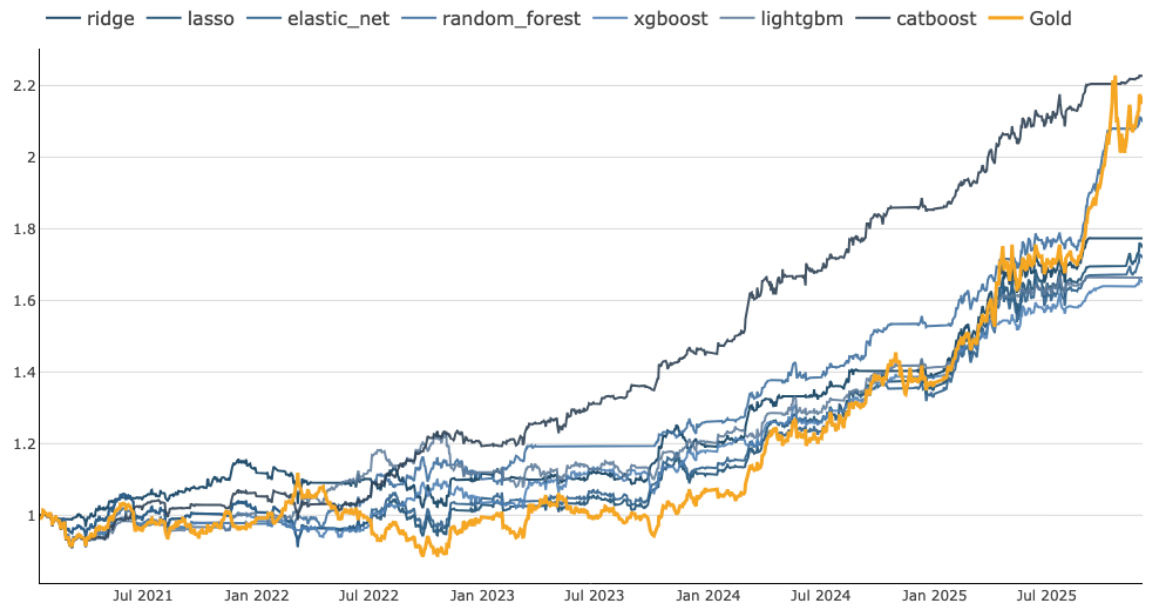

Рисунок 1: Накопленная доходность стратегий машинного обучения в сравнении с инвестированием в золото

6. Формирование портфеля и бэктест

Несмотря на то, что все рассматриваемые модели прогнозируют доходность одного и того же базового актива – 10-дневную логарифмическую доходность золота, соответствующие торговые стратегии не являются тождественными. Причина заключается в том, что разные модели генерируют различные по величине, знаку и устойчивости прогнозные сигналы, а значит, в рамках торгового правила, описанного в предыдущем подразделе, приводят к различным временным рядам торговых доходностей.

Иными словами, объектом комбинирования в данном случае выступают не сами активы, а стратегии, индуцированные разными моделями прогнозирования. Даже если все стратегии торгуют один и тот же инструмент, их доходности могут заметно различаться вследствие различий в чувствительности моделей к рыночным режимам, структуре ошибок прогноза и устойчивости сигналов во времени. Поэтому объединение таких стратегий в единый портфель позволяет не только повысить качество итогового сигнала, но и снизить модельный риск, то есть риск деградации результатов вследствие неустойчивости или локальной неэффективности отдельно взятой модели.

Пусть $\mu = (\mu_1, \dots, \mu_N)^\top$ обозначает вектор ожидаемых доходностей отдельных стратегий, а Σ – ковариационную матрицу их доходностей. В эмпирической реализации веса стратегий выбираются из регуляризованной задачи оптимизации среднего и риска, имеющей вид $\max_w \; w^\top \mu - \gamma \, w^\top \tilde{\Sigma} w$, где $\gamma > 0$ – параметр неприятия риска, а $\tilde{\Sigma} = \Sigma + \lambda I$ – регуляризованная ковариационная матрица.

В отличие от классической задачи максимизации коэффициента Шарпа, такая постановка является более устойчивой численно и удобной для учета ограничений на структуру портфеля. В частности, в работе используются ограничения $\sum_{i=1}^{N} w_i = 1$ и $\|w\|_1 \leq L$, где $L > 1$ задаёт допустимый уровень совокупного объёма позиций и тем самым ограничивает суммарный объём длинных и коротких позиций. Это позволяет учитывать возможность коротких позиций, одновременно предотвращая чрезмерно агрессивные решения. Подобная регуляризованная постановка задачи портфельной оптимизации широко используется в литературе для повышения устойчивости оценок риска (Jagannathan and Ma, 2003).

Регуляризация ковариационной матрицы

На практике доходности стратегий, построенных на прогнозах одного и того же актива, как правило, оказываются существенно коррелированными. Это означает, что ковариационная матрица Σ может быть плохо обусловленной или почти вырожденной, что делает её обращение численно нестабильным и приводит к неустойчивым оценкам оптимальных весов.

Для стабилизации решения используется диагональная регуляризация ковариацион-

ной матрицы:

$$\tilde{\Sigma} = \Sigma + \lambda I,$$

где I – единичная матрица, а $\lambda > 0$ – параметр регуляризации.

Кроме того, для снижения чувствительности к шуму в оценке ожидаемых доходностей применяется сглаживание среднего значения: $\tilde{\mu} = \alpha \mu$, где $0 < \alpha \leq 1$. Здесь α является параметром сглаживания. В практической реализации именно вектор $\tilde{\mu}$ используется в задаче оптимизации вместо исходной оценки μ.

Смысл данной регуляризации аналогичен регуляризации типа гребневой в задачах регрессии: добавление слагаемого λI снижает влияние сильной мультиколлинеарности между стратегиями, а сглаживание ожидаемых доходностей уменьшает чувствительность портфеля к ошибкам оценки среднего значения. В результате портфель становится более устойчивым.

Результаты бэктеста

Для оценки эффективности предложенной стратегии были рассчитаны стандартные показатели доходности и риска для отдельных моделей машинного обучения, агрегированного портфеля моделей и базового актива (золота). В качестве метрик использовались средняя дневная логарифмическая доходность, дневная волатильность, годовая доходность, годовая волатильность, коэффициенты Sortino и Calmar, совокупная доходность, максимальная просадка и доля прибыльных наблюдений.

Таблица 3: Показатели эффективности моделей, портфеля и базового актива

Стратегия	Год. дох.	Год. вол.	Calmar	Total Return	Max DD	Hit Ratio
CatBoost	21.88%	8.50%	2.880	113.48%	-7.60%	46.17%
Random Forest	22.31%	8.81%	3.333	116.37%	-6.69%	40.79%
XGBoost	14.70%	8.64%	2.078	69.18%	-7.07%	47.00%
LightGBM	14.89%	8.89%	1.231	70.27%	-12.10%	45.55%
LASSO	15.66%	10.85%	1.434	74.65%	-10.92%	45.45%
Elastic Net	15.09%	10.79%	1.382	71.41%	-10.92%	44.72%
Ridge	13.44%	10.39%	1.355	62.14%	-9.92%	40.27%
Gold	21.76%	15.71%	1.044	112.73%	-20.84%	52.90%
Portfolio	**17.22%**	**7.06%**	**4.377**	**83.86%**	**-3.93%**	**53.52%**

Как видно из Таблицы 3, некоторые отдельные модели демонстрируют более высокую годовую доходность по сравнению с агрегированным портфелем. Например, модели CatBoost и Random Forest показывают доходность выше 21% годовых. Однако при этом данные стратегии характеризуются более высокой волатильностью и большей

максимальной просадкой.

Агрегированный портфель моделей, напротив, демонстрирует значительно более устойчивый профиль риска. Несмотря на несколько более низкую среднюю доходность (17.22% годовых), он обладает существенно меньшей максимальной просадкой (-3.93%), высоким коэффициентом Шарпа 2.25 и более высоким коэффициентом Calmar[7]. Это указывает на более эффективное соотношение доходности и принимаемого риска.

Поскольку агрегированный портфель демонстрирует существенно более низкую волатильность и значительно меньшую просадку по сравнению с отдельными моделями и базовым активом, он позволяет диверсифицировать модельный риск за счёт комбинирования сигналов различных алгоритмов. В результате возникает возможность масштабирования стратегии с использованием умеренного кредитного плеча.

Рассмотрим применение плеча 2×. Соответствующие показатели эффективности представлены в Таблице 4.

Таблица 4: Показатели эффективности при использовании плеча 2×

Стратегия	Год. дох.	Год. вол.	Calmar	Total Return	Max DD	Hit Ratio
CatBoost	21.88%	8.50%	2.880	113.48%	-7.60%	46.17%
Random Forest	22.31%	8.81%	3.333	116.37%	-6.69%	40.79%
XGBoost	14.70%	8.64%	2.078	69.18%	-7.07%	47.00%
LightGBM	14.89%	8.89%	1.231	70.27%	-12.10%	45.55%
LASSO	15.66%	10.85%	1.434	74.65%	-10.92%	45.45%
Elastic Net	15.09%	10.79%	1.382	71.41%	-10.92%	44.72%
Ridge	13.44%	10.39%	1.355	62.14%	-9.92%	40.27%
Gold	21.76%	15.71%	1.044	112.73%	-20.84%	52.90%
Portfolio (2x)	**37.40%**	**14.11%**	**4.849**	**238.05%**	**-7.71%**	**53.52%**

После применения плеча годовая доходность портфеля увеличивается до 37.40%, при этом годовая волатильность возрастает до 14.11%. Максимальная просадка составляет -7.71%, что остается значительно ниже уровня просадки базового актива.

Таким образом, использование кредитного плеча позволяет существенно увеличить итоговую доходность стратегии при сохранении относительно умеренного уровня риска. Совокупная доходность портфельной стратегии достигает 238.05%, что значительно превосходит как отдельные модели, так и базовый актив.

[7]Коэффициент Calmar определяется как отношение годовой доходности стратегии к её максимальной просадке:

$$\text{Calmar} = \frac{R_{\text{annual}}}{|\text{MDD}|}.$$

Здесь R_{annual} обозначает годовую доходность стратегии, а MDD – максимальную просадку.

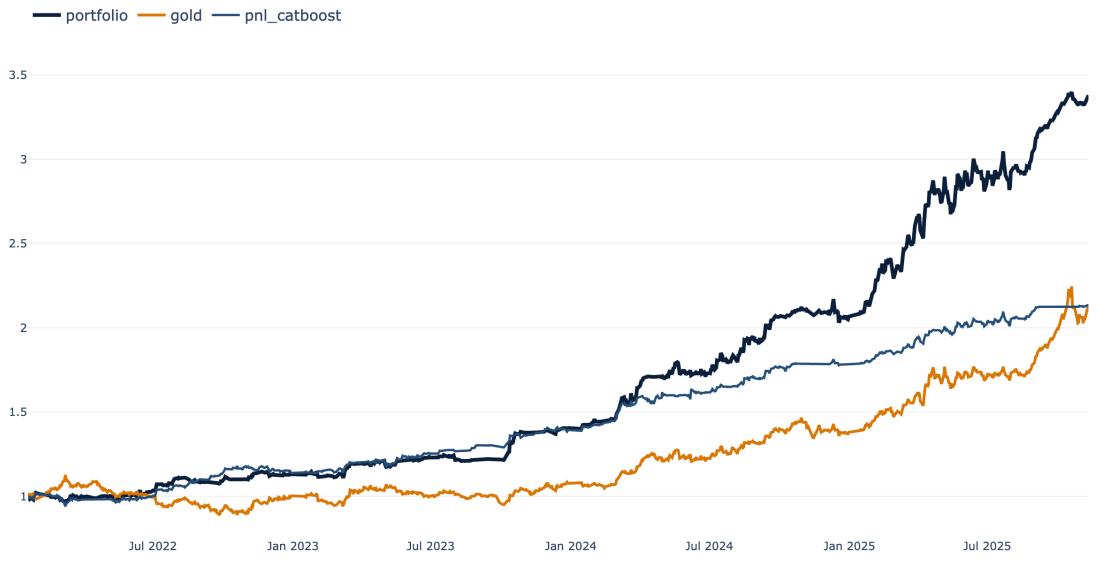

Рисунок 2: Накопленная доходность портфельной стратегии в сравнении с инвестированием в золото

7. Заключение

В данной работе была исследована задача прогнозирования доходности золота и построения торговой стратегии на основе методов машинного обучения. Основное внимание уделялось формированию информативного набора признаков, отражающих различные каналы формирования цены золота: динамику товарных рынков, макрофинансовые показатели, процентные ставки, валютные факторы, индикаторы рыночной неопределенности и позиционирование участников рынка.

Полученные результаты показывают, что грамотная процедура *feature engineering* и строгий отбор признаков способны обеспечить достаточно высокое качество прогнозов даже при использовании одной модели машинного обучения. В частности, ряд алгоритмов продемонстрировал устойчивую предсказательную способность и позволил построить торговые стратегии с положительными риск-скорректированными характеристиками.

Важным результатом работы является то, что комбинирование моделей в рамках портфельного подхода позволяет существенно повысить устойчивость итоговой стратегии. Хотя отдельные модели могут демонстрировать более высокую доходность, объединение стратегий на основе оптимизации типа Марковица позволяет снизить модельный риск, возникающий из-за нестабильности отдельных алгоритмов. В результате агрегированный портфель обладает более благоприятным профилем риска, более высоким коэффициентом Шарпа и меньшими просадками, что делает стратегию более

устойчивой во времени.

Несмотря на полученные результаты, проведённое исследование имеет ряд ограничений. Во-первых, при расчёте показателей эффективности не учитывались транзакционные издержки, а также безрисковая ставка при вычислении коэффициента Шарпа, что может приводить к некоторому завышению риск-скорректированной доходности. Во-вторых, анализ проводился на ограниченной исторической выборке, начинающейся с 2010 года, что не позволяет в полной мере учитывать более долгосрочные структурные изменения на рынке золота. Кроме того, в рамках данной работы для упрощения эмпирического анализа в качестве основной целевой переменной была выбрана логарифмическая доходность золота на горизонте 10 торговых дней. Хотя предварительный анализ показал, что данный горизонт демонстрирует наиболее устойчивые статистические характеристики, ограничение исследования одним горизонтом может сужать возможности построения торговых стратегий. В дальнейшем представляется перспективным рассматривать стратегии, использующие несколько горизонтов прогнозирования, что может позволить более полно учитывать различные временные структуры динамики доходности золота.

Перспективным направлением дальнейших исследований является расширение временного горизонта данных, что позволит более полно учитывать различные фазы рыночного цикла. Кроме того, поскольку золото традиционно рассматривается как актив-убежище, можно предположить существование различных рыночных режимов (например, *risk-on*, *risk-off* и нейтральных состояний), в рамках которых структура зависимостей между факторами и доходностью золота может существенно меняться. Для моделирования подобных эффектов могут быть использованы модели с марковскими переключениями (*Markov switching models*), позволяющие формально учитывать смену рыночных режимов.

Дополнительным направлением развития может стать использование методов глубокого обучения, например моделей, в которых скрытые рыночные состояния формируются с помощью вариационных автоэнкодеров (VAE).[8] Также перспективным является применение методов обучения с подкреплением (*reinforcement learning*), позволяющих напрямую оптимизировать торговые решения и динамическое управление позицией.

Наконец, важным источником повышения устойчивости стратегии может быть дальнейшая диверсификация модельных сигналов. Поскольку каждая модель генерирует собственный поток доходностей (PnL), увеличение числа моделей и торговых стратегий позволяет снижать модельный риск и улучшать риск-скорректированные характеристики портфеля. Кроме того, расширение стратегии на другие товарные рынки может снизить корреляцию между потоками доходностей и тем самым дополнительно увеличить коэффициент Шарпа итогового портфеля.

[8] Авторы признательны Багирову Г. Т. за предложенную идею использования VAE

Приложение А

Таблица 5: Описание используемых переменных

Номер	Короткое название	Описание данных	Частота
1	Date	Дата, в формате год-месяц-день	D
2	wti_price	Цена закрытия нефти WTI	D
3	silver_open	Цена открытия спота на серебро	D
4	silver_close	Цена закрытия спота на серебро	D
5	silver_high	Наивысшая цена спота на серебро	D
6	silver_low	Наименьшая цена спота на серебро	D
7	gold_open	Цена открытия спота на золото	D
8	gold_close	Цена закрытия спота на золото	D
9	gold_high	Наивысшая цена спота на золото	D
10	gold_low	Наименьшая цена спота на золото	D
11	spx_open	Цена открытия индекса S&P 500	D
12	spx_close	Цена закрытия индекса S&P 500	D
13	spx_high	Наивысшая цена индекса S&P 500	D
14	spx_low	Наименьшая цена индекса S&P 500	D
15	spx_volume	Объем торгов индексом S&P 500	D
16	BONDS_10Y	Доходность 10-летних казначейских облигаций США	D
17	BONDS_1Y	Доходность 1-летних казначейских облигаций США	D
18	EPU	Индекс геополитической напряженности	D
19	BEI_10Y	Breakeven inflation (10Y)	D
20	MOVE	Ожидаемая волатильность облигационного рынка	D
21	CRB	Индекс цен сырьевых товаров (CRB)	D
22	DXY	Индекс доллара США	D
23	OAS	Option-adjusted spread	D
24	VIX	Индекс волатильности CBOE	D
25	GVZ	Индекс волатильности золота (GVZ)	D
26	btc_open	Цена открытия спота на биткоин	D
27	btc_close	Цена закрытия спота на биткоин	D
28	btc_high	Наивысшая цена спота на биткоин	D
29	btc_low	Наименьшая цена спота на биткоин	D
30	F1-F4	Котировки ближайших к экспирации фьючерсов на золото	D
31	V1-V4	Объемы торгов ближайших фьючерсов на золото	D
32	OI1-OI4	Открытый интерес ближайших фьючерсов на золото	D

Номер	Короткое название	Описание данных	Частота
33	DTE1-DTE4	Дни до экспирации фьючерсных контрактов	D
34	Comm_Agg_Net	Чистая позиция коммерческих участников (Long–Short)	W
35	NonComm_Agg_Net	Чистая позиция некоммерческих участников	W
36	SmallSpec_Net	Чистая позиция мелких спекулянтов (Non-reportables)	W
37	Comm_Prod_Net	Чистая позиция производителей/мерчантов/процессоров	W
38	Comm_Swap_Net	Чистая позиция своп-дилеров	W
39	MM_Net	Чистая позиция Money Managers (CTA, hedge funds)	W
40	OtherRep_Net	Чистая позиция категории Other Reportables	W
41	TIPS_10Y	Доходность 10-летних TIPS	D
42	copper_open	Цена открытия ближайшего фьючерса на медь	D
43	copper_close	Цена закрытия ближайшего фьючерса на медь	D
44	copper_high	Наивысшая цена ближайшего фьючерса на медь	D
45	copper_low	Наименьшая цена ближайшего фьючерса на медь	D
46	copper_volume	Объем торгов ближайшего фьючерса на медь	D
47	jpy_open	Цена открытия спота JPY/USD	D
48	jpy_close	Цена закрытия спота JPY/USD	D
49	jpy_high	Наивысшая цена спота JPY/USD	D
50	jpy_low	Наименьшая цена спота JPY/USD	D
51	eur_open	Цена открытия спота EUR/USD	D
52	eur_close	Цена закрытия спота EUR/USD	D
53	eur_high	Наивысшая цена спота EUR/USD	D
54	eur_low	Наименьшая цена спота EUR/USD	D

Приложение Б

Таблица 6: Сравнение качества прогнозов для различных горизонтов доходности золота

Горизонт	Mean IC	Median IC	Std(IC)	Доля (IC> 0)	*t*-stat IC
70	0.480	0.800	0.460	0.80	2.33
50	0.406	0.543	0.224	1.00	4.06
30	0.342	0.342	0.334	0.60	2.29
55	0.340	0.500	0.546	0.80	1.39
10	0.334	0.293	0.203	1.00	3.68
65	0.320	0.400	0.657	0.80	1.09
40	0.243	0.143	0.340	0.80	1.60
35	0.238	0.167	0.497	0.60	1.07
3	0.218	0.259	0.126	0.80	3.85
5	0.211	0.193	0.163	0.80	2.89
60	0.180	0.100	0.335	0.80	1.20
15	0.166	0.147	0.224	0.80	1.66
25	0.158	0.127	0.154	0.80	2.30
2	0.121	0.132	0.092	1.00	2.93
1	0.098	0.124	0.072	0.80	3.05
20	0.018	-0.121	0.241	0.40	0.16
45	-0.006	-0.029	0.192	0.40	-0.07

Примечание: для расчёта метрик используются неперекрывающиеся наблюдения. Для n-дневной доходности выборка формируется с шагом n торговых дней.

Таблица 7: Сравнение моделей машинного обучения по информационному коэффициенту (IC) и средней квадратичной ошибке (MSE)

Модель	IC	σ_{IC}	t-stat$_{IC}$	MSE
CatBoost	0.2144	0.0857	2.502	0.00096
Random Forest	0.2140	0.1401	1.528	0.00095
Lasso	0.2095	0.1943	1.078	0.00109
XGBoost	0.2052	0.1629	1.260	0.00106
Elastic Net	0.2034	0.1890	1.076	0.00109
Ridge	0.1949	0.1653	1.179	0.00120
LightGBM	0.1722	0.1463	1.178	0.00113

Примечание: в таблице представлены средние значения метрик по шести временным фолдам.